AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad: Muhammed Eren Aydin Ogr. No: 230541034 Tarih: 08.11.2026

Kavram: Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin dışında tanımlanmalıdır. Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

Kurgu: Kamera → YZ Modeli (ahşap yüzey/kusur sınıflandırma) → OK / RED → Parametre (kafa basıncı, besleme hızı) → Makine. YZ yalnızca kalite ve parametre önerisi üretir; insan güvenliği YZ'nin dışındaki safety mimarisince sağlanır.

Görev — üç başarısızlıkta güvenli davranış

1. Model yanlış sınıflandırdı: YZ'nin kararı doğrudan kritik harekete gitmez; kural tabanlı sınır değerler (maksimum basınç/hız) ve çıkışta örnekleme/insan onayı ikinci kontrol olarak uygulanır. Parametre önerisi PLC'de sabit güvenli sınırlarla kırpılır; sınırı aşan öneri reddedilir. Safety fonksiyonu modele hiç bağlı değildir.

2. Girdi manipüle edildi: Görüntü kalite ve tutarlılık kontrolleri (donmuş kare, parlaklık/netlik, zaman damgası), ikinci sensörle çapraz doğrulama (örn. kalınlık sensörü) ve girdi dağılımı izleme ile fark edilir. Şüpheli girdide model çıktısı yok sayılır, makine fallback moduna (sabit güvenli parametre veya durdur) geçer ve olay kaydedilir.

3. Confidence düştü: Eşik risk bazlı ve YZ dışında tanımlanır (örnek başlangıç: %90; gerçek değer test verisiyle doğrulanmalı). Eşik altında model kararı kullanılmaz: parça RED/manuel kontrole yönlendirilir, parametre son bilinen güvenli değerde sabit tutulur; art arda düşük güvende makine durur ve insana sorar.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Güvenli davranış	Kavram
Model yanlış sınıflandırdı	Parametre sabit güvenli sınırlarla kırpılır, çıkışta ikinci kontrol veya örnekleme; safety fonksiyonu YZ'den bağımsız	human override + fail-safe
Girdi manipüle edildi	Girdi doğrulama ve çapraz sensör kontrolü; şüphede model devre dışı, fallback veya durdurma, olay kaydı	monitoring + fallback
Confidence düştü	Eşik altında YZ kararı kullanılmaz; manuel kontrol veya son güvenli parametre; tekrarlarsa durdur ve insana sor	confidence threshold + human override

Bu föyün çıktısı AI Fail-Safe Decision → Evidence Pack EP 03 + EP 15 başlığına oturur.