LABORATUVAR 7 · MİRKA SMART WOODSANDER 5000 · Ahşap Zımpara Makinesi

AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad: Muhammed Eren Aydin Ogr. No: 230541034 Tarih: 08.11.2026

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır. Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

Senaryo: WoodSander 5000'e YZ'li yüzey kalite kontrolü (çizik, yanık izi, düzensiz zımpara tespiti) ve buna bağlı otomatik ret/ayarlama eklenmesi planlanıyor — proje aşaması değerlendirmesi.

Kamera → **YZ Modeli** → **OK / RED** → **Ret mekanizması** → **Hat/besleme hızı**

*Tasarım ilkesi: YZ yalnızca **kalite** kararı verir; zımpara kafası, kapak kilidi, ışık perdesi, STO gibi **emniyet fonksiyonlarına hiçbir komut yetkisi yoktur**.*

Görev — üç başarısızlıkta güvenli davranış

1 **Model yanlış sınıflandırdı: Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?**

Kalite hatası emniyet olayı değildir ama **zincir korunmalı**: (1) bağımsız ikinci kontrol — yapay zekâ dışı sensör (örn. lazer kalınlık/yüzey sensörü) ve **periyodik/örneklemeli insan kontrolü**; (2) hata oranı izleme (monitoring): kaçak oranı eşiği aşarsa YZ'yi devre dışı bırakıp tam manuel kontrole dön; (3) YZ kararı hiçbir zaman makine emniyetini veya hızını tek başına değiştirmez.

2 **Girdi manipüle edildi: Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?**

Fark etme: görüntü kalitesi/aydınlatma kontrolü (toz lekesi, bulanıklık, kapalı lens), kare sayısı/zaman damgası/akış bütünlüğü, kamera kimlik doğrulama ve imzalı/izole ağ, ani istatistik kayması, beklenen parça geometrisi ile tutarsızlık. **Şüpheli girdide:** YZ kararı **kullanılmaz** → parça "belirsiz/RED" olarak ayrılır, insan kontrolüne yönlenir, alarm verilir; tekrarlarsa hat güvenli ve kontrollü şekilde durdurulur ve olay kaydı açılır (bkz. LAB 6).

3 **Confidence düştü: Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?**

Örnek eşik (pilot sonucu kalibre edilmeli): ≥ %90 → otomatik karar; %70–%90 → **insana sor** (parça yan hatta, operatör onayı); < %70 veya art arda N parça belirsiz → **fallback** (manuel/kural tabanlı kontrol) ve hat kontrollü yavaşlatılır/durdurulur. Eşik kalibrasyonu gerçek hata maliyetine göre test verisiyle yapılır; sessiz düşüş (drift) izlenir.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	Bağımsız ikinci kontrol + periyodik insan onayı; kaçak oranı eşiği aşarsa YZ devre dışı, manuel kontrole dön. **(human override + monitoring)**
Girdi manipüle edildi	Girdi doğrulama başarısız → parça "belirsiz/RED", insan kontrolü, alarm; tekrarında kontrollü durdurma. **(fail-safe + monitoring)**
Confidence düştü	≥%90 otomatik; %70–90 insana sor; <%70 fallback (manuel/kural tabanlı) ve gerekirse kontrollü durdurma. **(confidence threshold + fallback)**

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.